VJEŽBA 2: RAD S DODATNIM PYTHON BIBLIOTEKAMA.

I. Cilj vježbe:

Upoznati se s načinom korištenja dodatnih Python biblioteka/modula: Numpy i Matplotlib.

II. Opis vježbe:

Za Python je napisan veliki broj biblioteka koje olakšavaju programiranje. U ovoj vježbi studenti se upoznaju s *numpy* bibliotekom koja olakšava numeričke proračune i *matplotlib* bibliotekom za grafički prikaz rezultata.

II.1. Numpy

`Numpy` je open source Python biblioteka za numeričke proračune. Sadrži niz brzih unaprijed prevedenih funkcija za različite numeričke rutine. Ovo je važno kada se razmatraju problemi strojnog učenja u kojima se provode različite optimizacije na temelju raspoloživih podataka. Prednosti korištenja Numpy biblioteke u odnosu na osnovni Python i liste su efikasno (brzo) matrično računanje te efikasna implementacija polja (engl. *array*). Osnovni objekt Numpy biblioteke je višedimenzionalno polje `ndarray` za pohranu podataka koji su istog tipa (uobičajeno cjelobrojni brojevi ili brojevi s pomičnim zarezom). Koristi se za predstavljanje vektora (1D polje), matrica (2D polja) ili višedimenzionalnih polja. Naredbom `import numpy` učitava se numpy biblioteka. Tada se raspoloživim funkcijama pristupa na način `numpy.ime_funkcije`. Stoga se često zbog kraćeg zapisa koristi *alias:*

```
import numpy as np
```

pa se metodama pristupa na način `np.ime_funkcije`.

Numpy polje definira se pozivanjem funkcije `array`. Ovaj objekt tada sadrži sljedeće atribute:

- `ndim` – broj dimenzija,
- `shape` – dimenzija polja. Za matricu dimenzija NxM, shape attribute je tuple (N, M),
- `size` – ukupni broj elemenata u polju,
- `dtype` – tip elemenata u polju.

Elementi numpy polja indeksirani su pozitivnim cijelim brojevima. Iz polja je moguće izdvajati dijelove polja pomoću operatora : na isti način kao i kod Python lista. Nadalje, postoje funkcije za kreiranje polja koje sadrži nule (`zeros`), jedinice (`ones`), konstantu (`full`), jediničnu matricu (`eye`) i sl. Neki primjeri korištenja numpy biblioteke dani su u primjeru 2.1.

Primjer 2.1.

```
import numpy as np

a = np.array([6, 2, 9])        #napravi polje od tri elementa
print(type(a))                 #prikaži tip polja
print(a.shape)                 #koliko elemenata ima vektor
print(a[0], a[1], a[2])        #prikaži prvi, drugi i treći element
a[1] = 5                       #promijeni vrijednost polja na drugom mjestu
print(a)                       #prikaži cijeli a
print(a[1:2])                  #izdvajanje
print(a[1:-1])                 #izdvajanje

b = np.array([[3,7,1],[4,5,6]])     #napravi 2 dimenzionalno polje (matricu)
print(b.shape)                      #ispiši dimenzije polja
print(b)                            #ispiši cijelo polje b
print(b[0, 2], b[0, 1], b[1, 1])    #ispiši neke elemente polja
print(b[0:2,0:1])                   #izdvajanje
print(b[:,0])                       #izdvajanje

c = np.zeros((4,2))            #polje sa svim elementima jednakim 0
d = np.ones((3,2))             #polje sa svim elementima jednakim 1
e = np.full((1,2),5)           #polje sa svim elementima jednakim 5
```

```
f = np.eye(2)                    #jedinična matrica 2x2

g = np.array([1, 2, 3], np.float32)
duljina  = len(g)
print(duljina)
h = g.tolist()
print(h)
c = g.transpose()
print(g)
np.concatenate((a, g,))
```

Unutar Numpy biblioteke dostupne su matematičke operacije s numpy poljima poput zbrajanja, množenja i ostalih uobičajenih matematičkih operacija, zatim funkcija za sumiranje polja, traženje maksimalne/minimalne vrijednosti unutar polja, sortiranje i sl.

Primjer 2.2.

```
import numpy as np

a = np.array([3,1,5], float)
b = np.array([2,4,8], float)
print(a+b)
print(a-b)
print(a*b)
print(a/b)

print(a.min())
print(a.argmin())
print(a.max())
print(a.argmax())
print(a.sum())
print(a.mean())

print(np.mean(a))
print(np.max(a))
print(np.sum(a))

a.sort()
print(a)
```

Unutar Numpy biblioteke nalaze se osnovne „statističke“ funkcije poput srednje vrijednosti, varijance i standardne devijacije. Također je na raspolaganju generator slučajnih brojeva (različite distribucije).

Primjer 2.3.

```
import numpy as np

np.random.seed(56)                  #postavi seed generatora brojeva
rNumbers = np.random.rand(10)       #generiraj 10 slučajnih brojeva
print(rNumbers)
print(rNumbers.mean())
```

II.2. Matplotlib

`Matplotlib` biblioteka sadrži različite funkcije za kreiranje statičkih i dinamičkih vizualizacija `matplotlib.pyplot` je sučelje koje omogućava izradu različitih prikaza. Ovo sučelje kreira sliku (engl. *figure*) koje se ujedno ponaša kao i grafičko sučelje. Primjer crtanja sinus i kosinus funkcije u rasponu od 0 do 6 dan je u primjer 2.4. Funkcija `.plt()` prima dva numpy polja (vrijednosti x i y osi) te spaja točke ravnim linijama. Dodatnim funkcijama moguće je označiti osi, dati naslov slici i sl.

Primjer 2.4.

```
#primjer vizualizacije

import numpy as np
import matplotlib.pyplot as plt

x = np.linspace(0, 6, num=30)
y= np.sin(x)
plt.plot(x, y, 'b', linewidth=1,  marker=".", markersize=5)
plt.axis([0,6,-2,2])
plt.xlabel('x')
plt.ylabel('vrijednosti funkcije')
plt.title('sinus funkcija')
plt.show()
```

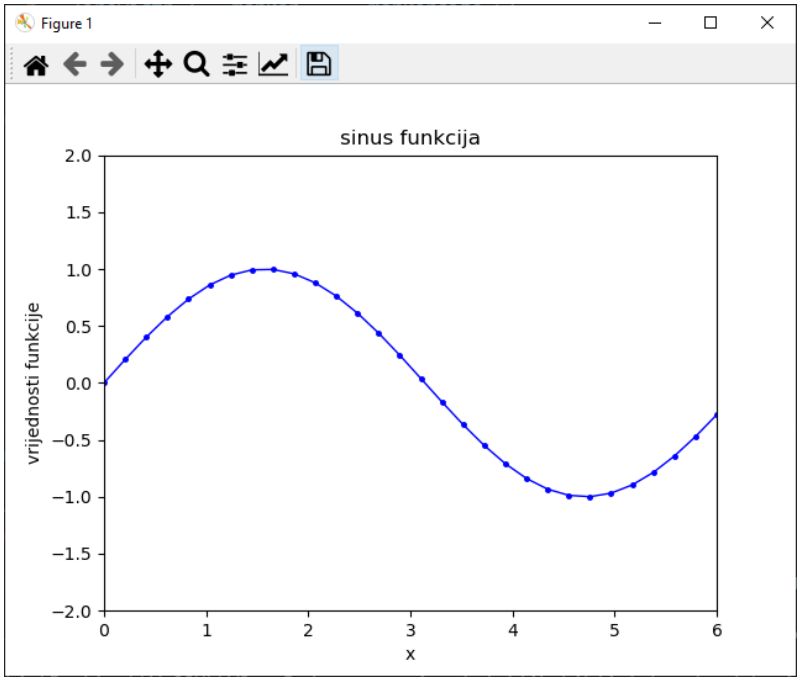

Sl. 2.1. matplotlib.pyplot slika

Digitalna slika sastoji se od osnovnih elemenata koji se nazivaju pikseli. Digitalna slika se u Pythonu predstavlja numpy poljem pri čemu svaki element numpy polja odgovara jednom pikselu na slici. Vrijednosti elemenata se kreću od 0 (crna boja) do 255 (bijela boja) kao što je prikazano na slici 2.2. Prilikom učitavanja slike neke biblioteke skaliraju vrijednosti piksela na raspon od 0-1 (kao npr. matplotlib).

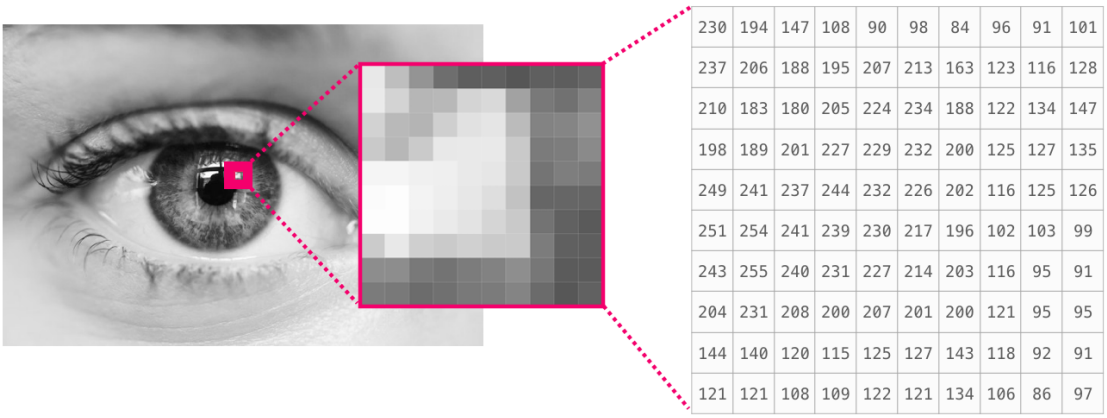

230	194	147	108	90	98	84	96	91	101
237	206	188	195	207	213	163	123	116	128
210	183	180	205	224	234	188	122	134	147
198	189	201	227	229	232	200	125	127	135
249	241	237	244	232	226	202	116	125	126
251	254	241	239	230	217	196	102	103	99
243	255	240	231	227	214	203	116	95	91
204	231	208	200	207	201	200	121	95	95
144	140	120	115	125	127	143	118	92	91
121	121	108	109	122	121	134	106	86	97

Sl. 2.2. Primjer slike u sivim tonovima i način predstavljanja slike kao 2D polja.

Na sličan način se u memoriju računala pohranjuju slike u boji. Najčešći način zapisivanja slike u boji je u RGB formatu. Tada je slika u memoriji prikazana s tri kanala (matrice) pri čemu prva matrica predstavlja udio crvene, druga matrica udio zelene, a treća matrica udio plave boje za svaki piksel.

Učitavanje slika s medija za pohranu (npr. hardisk) radi se pomoću `matplotlib.pyplot.imread` funkcije. Potrebno je predati putanju do slike u obliku stringa, a funkcija vraća numpy polje koje predstavlja sliku. Slike se učitavaju u 3D dimenzionalno polje bez obzira radi li se o slici u boji ili slici u sivim tonovima. U slučaju slika u sivim tonovima, sva tri kanala će imati jednake vrijednosti pa je dovoljno koristiti samo jedan.
Primjer 2.5 prikazuje kako se učitava i prikazuje slika 'road.jpg' koja je slika u sivim tonovima. Iz dobivenog 3D polja odabire se samo prvi kanal. Slika je tada predstavljena 2D numpy poljem čiji `shape` je jednak rezoluciji slike. Učitana slika se može prikazati pomoću funkcije `matplotlib.pyplot.imshow` na način da joj se preda numpy polje koje odgovara slici.

Primjer 2.5.

```
import numpy as np
import matplotlib.pyplot as plt

img = plt.imread("tiger.png")
img = img[:,:,0].copy()
print(img.shape)
print(img.dtype)

plt.figure()
plt.imshow(img, cmap="gray")
plt.show()
```

III. Priprema za vježbu:

1. Proučite primjere 2.1. do 2.4. Možete li opisati što je rezultat izvođenja svake linije koda u navedenim primjerima?

2. Proučite kako se zapisuje slika u sivim tonovima u memoriju računala. Pogledajte primjer 2.5. koji učitava sliku pomoću biblioteke matplotlib.

IV. Rad na vježbi:

1. Isprobajte Python primjere iz II. Opis vježbe u Visual Studio Code IDE. Razmislite o svakoj liniji programskog koda i što je njen rezultat. Pokrenite primjere u *Debug* modu i pogledajte u *Explorer*-u kako izgleda svaka od varijabli u danim primjerima.

2. Riješite dane zadatke.

Zadatak 1

Pomoću funkcija `numpy.array` i `matplotlib.pyplot` pokušajte nacrtati sljedeću sliku:

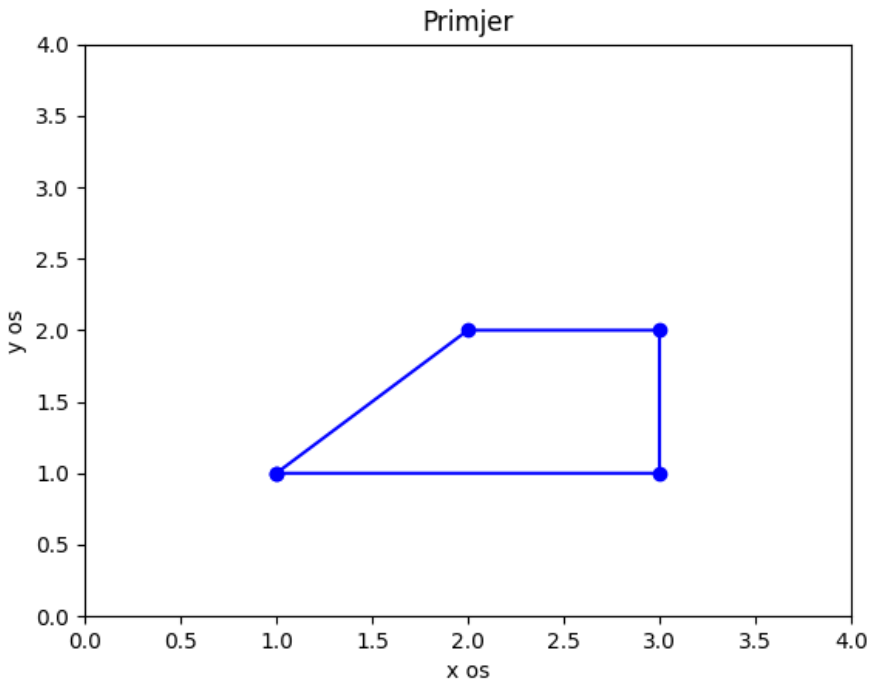

Igrajte se sa slikom, promijenite boju oblika, debljinu linije i sl.

Zadatak 2

U direktoriju `PSU_LV/LV2/` nalazi se datoteka `mtcars.csv` koja sadrži različita mjerenja provedena na 32 automobila (modeli 1973-74). Opis pojedinih varijabli nalazi se u datoteci `mtcars_info.txt`.

a) Učitajte datoteku `mtcars.csv` pomoću:
```
data = np.loadtxt(open("mtcars.csv", "rb"), usecols=(1,2,3,4,5,6), delimiter=",", skiprows=1)
```
b) Prikažite ovisnost potrošnje automobila (`mpg`) o konjskim snagama (`hp`) pomoću naredbe `matplotlib.pyplot.scatter`.
c) Na istom grafu prikažite i informaciju o težini pojedinog vozila (npr. veličina točkice neka bude u skladu sa težinom `wt`).
d) Izračunajte minimalne, maksimalne i srednje vrijednosti potrošnje (`mpg`) automobila.
e) Ponovite zadatak pod d), ali samo za automobile sa 6 cilindara (`cyl`).

Zadatak 3

Na temelju primjera 2.5. učitajte sliku 'tiger.png'. Manipulacijom odgovarajuće numpy matrice pokušajte:

a) posvijetliti sliku (povećati *brightness*),
b) zarotirati sliku za 90 stupnjeva u smjeru kazaljke na satu,
c) zrcaliti sliku,
d) smanjiti rezoluciju slike x puta (npr. 10 puta),
e) prikazati samo drugu četvrtinu slike po širini, a prikazati sliku cijelu po visini; ostali dijelovi slike trebaju biti crni.

Zadatak 4

Napišite funkciju koja kao povratnu vrijednost daje sliku (polje) sa crno bijelim kvadratima jednake dimenzije koji se naizmjenično pojavljuju (vidi primjer slike ispod). Funkcija kao argumente prima veličinu kvadrata u pikselima, broj kvadrata po visini i broj kvadrata po širini slike. Za realizaciju ove funkcije koristite `numpy` funkcije `zeros` i `ones` kako biste kreirali crna i bijela polja. Kako bise ih složili u odgovarajući oblik koristite numpy funkcije `hstack` i `vstack`. Za prikaz *grayscale* slike koristite naredbu:

```
plt.imshow(img, cmap='gray', vmin=0, vmax=255)
```

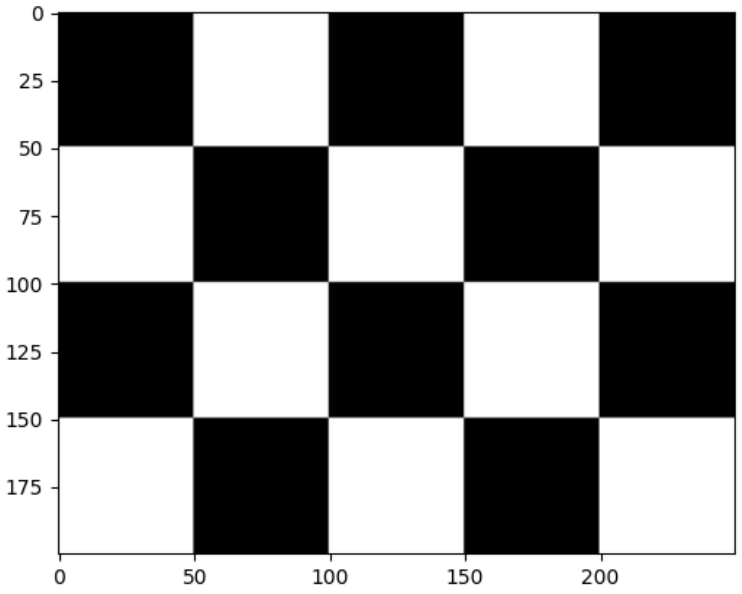

V. Izvještaj s vježbe

Kao izvještaj s vježbe prihvaća se web link na repozitorij pod nazivom `PSU_LV`.